PROCESSO SELETIVO · ÁREA DE IA · MÉTODO VDE

Case: classificação de tópicos

Pôr um modelo de linguagem para classificar e outro para conferir, nós já sabemos fazer. Queremos ver o sistema de classificação que você constrói: os dados organizados, o modelo e a regra de decisão são seus.

Prazo
a combinar

Anexos
anexos-case-ia.zip

Contato
carla@viciodeumaestudante.com.br

1. Contexto

A plataforma tem dezenas de milhares de questões de concursos jurídicos. O aluno estuda por **tópico**: escolhe "Lei Maria da Penha" ou "Juiz das Garantias" e resolve as questões ligadas a ele. Se a classificação está errada, ele estuda a matéria errada, perde tempo e perde a confiança na plataforma.

Boa parte das questões foi classificada automaticamente. O resultado criou o que chamamos de **lixeiras**: tópicos genéricos e introdutórios que atraíram centenas de questões que não têm nada a ver com eles. Os alunos perceberam e começaram a reportar. E toda semana chegam questões novas, de concursos novos, que precisam ser classificadas.

Você vai trabalhar num recorte real desse problema: **659 questões** de Penal, Processo Penal, Legislação Penal Especial e Criminologia, com os dados do jeito que estão, inclusive com os defeitos.

2. O que você recebe

Arquivo	Conteúdo
`questoes.jsonl`	659 questões: enunciado (HTML cru), comando, alternativas, disciplina e assunto de origem. Q0001 a Q0359 vêm do nosso banco; Q0360 a Q0659 são de concursos recentes, como numa importação nova.
`temas.csv`	Os 377 temas em que as questões podem ser classificadas, em árvore (disciplina → tema → subtema), exatamente como estão hoje na plataforma.
`folha_verdade.csv`	**100 questões classificadas pela nossa equipe de especialistas.** Use como quiser (para treinar, calibrar ou testar) e explique como usou.
`LEIA-ME.md`	Dicionário dos campos e formato exato dos arquivos de entrega.

Guardamos a classificação da equipe para as demais questões e avaliamos a sua entrega nelas. Os IDs (Q0001…) são exclusivos deste case.

3. A decisão que você precisa tomar

Para cada questão você decide uma de três coisas:

Decisão	Significado	Custo

publicar	Vai direto para o aluno, no tema que você escolheu.	Se estiver errado, o aluno estuda errado. É o erro mais caro.
revisar	Vai para a fila do professor, com a sua sugestão.	Tempo do professor, que é escasso.
fora	Nenhum tema da árvore serve.	A questão some do recorte até alguém criar o tema.

A régua

Das questões que você publicar, pelo menos 95% precisam estar certas. Respeitada essa condição, quanto mais você publicar, melhor; o que sobrar vai para revisão.

Conta como certo publicar no tema que a equipe atribuiu à questão, ou num nó do mesmo ramo (pai ou filho dele), porque o aluno que estuda um tema também vê as questões dos subtemas. Publicar em outro subtema do mesmo tema conta como erro.

---

4. O desafio: um sistema de classificação seu

Construa um sistema que decida o tema de cada questão. Ele pode combinar o que você quiser: embeddings, busca, regras sobre a árvore e sobre as leis citadas, um dicionário de termos, um classificador treinado, kNN, um modelo de ranqueamento. O que importa é que **a decisão seja do seu sistema** e que ele devolva uma probabilidade que você consiga calibrar.

Onde um modelo de linguagem pode entrar

Pode, antes da decisão e sempre documentado e versionado: gerar embeddings, limpar e normalizar o texto, extrair a lei e o artigo citados, enriquecer a descrição dos temas, propor termos ou exemplos que você revisa e guarda como dado.

Não pode escolher o tema, votar, julgar ou validar as questões avaliadas. Na hora de classificar, o seu sistema precisa rodar sem chamar nenhum modelo de linguagem.

Não esperamos que você saiba Direito nem que classifique questões à mão. A folha-verdade existe para isso. Organizar o conhecimento que está nos dados (a árvore, as leis, os termos, os 100 exemplos) é o centro do trabalho.

---

5. O que entregar

1. `publicacao.csv`
   Uma linha por questão (as 659), com a decisão (`publicar`, `revisar` ou `fora`), o tema central, os extras e a sua confiança. O formato está no `LEIA-ME.md`.

2. `previsao.txt`**: a sua autoavaliação**
   Antes de saber o resultado, diga qual será a sua **precisão** nas publicadas e a sua **cobertura** (fração publicada) nas questões fora da folha-verdade, cada uma com um intervalo. Explique como chegou nesses números. Comparamos a previsão com o resultado real.

3. **Código**
   Um comando que regenera o `publicacao.csv` a partir dos anexos, **sem chamar modelo de linguagem**. Os artefatos que você construiu (dicionários, regras, embeddings em cache, modelo treinado) ficam versionados no repositório. O README diz como rodar, quanto tempo leva e de onde veio cada artefato. Se alguma decisão foi tomada à mão, registre qual e por quê.

4. **Relatório** (até 4 páginas)
   a) O sistema. O que você construiu, peça por peça, e por que cada peça está ali. Inclua o que testou e descartou.

   b) Os 100 rótulos. Como você os usou (treino, calibração, teste) e o que eles mostraram sobre o seu sistema e sobre a convenção da equipe.

   c) Diagnóstico. O que nos dados e nos temas atrapalha a classificação, que tipos de questão o sistema ainda erra e o que resolveria cada um.

   d) Produção. Custo e tempo para 50 mil questões por semana, como a correção do professor vira dado de treino e de quanto em quanto tempo o sistema se retreina.

   e) Memo para o professor (1 página). Ele é especialista em Direito, não em IA. O que você encontrou, o que recomenda mudar nos temas e do que precisa dele.

Como entregar: crie um **repositório público no GitHub** com `publicacao.csv`, `previsao.txt`, o relatório (PDF ou Markdown) e o código, e envie o link para **carla@viciodeumaestudante.com.br**.

---

6. Regras

- **Ferramentas:** use as suas. Não reembolsamos custos. Um sistema que roda num notebook comum é tão bom quanto um que precisa de GPU.
- **Prazo:** a combinar. Se não terminar tudo, diga o que faria com mais tempo.
- **Dúvidas:** escreva para **carla@viciodeumaestudante.com.br**.

---

7. Como avaliamos

O que pesa

- Cobertura com precisão ≥ 95% nas questões fora da folha-verdade
- Como você organizou os dados e o que o sistema aprende com eles
- O quanto a sua previsão acerta o seu próprio resultado
- Rodar de novo, do zero, sem modelo de linguagem na decisão

O que não pesa

- Usar o modelo mais sofisticado
- Infraestrutura ou volume de código
- Volume de páginas
- Saber Direito Penal de cor (ajuda, mas não é requisito)